

工作进度汇报

汇报人：谭成 日期：2026年7月10日

本周状态：一边跑服务器实验收 Phase R 数据，一边把 Option BTCM 从“伪代码”落到“代码”，BTCM 骨架已经在服务器跑通 50ep 冒烟。实验入口：服务器 `bash /home/ubuntu/workplace/tc2/GBGCL-main/scripts/phases/run_phase_nohup.sh R` 与 `bash scripts/start_smoke.sh`，本地 `tools/analyze_phaseR.py`。

一、近期工作概述

本周主要推进了三项工作。第一项是 Option BTCM 从设计稿落地为可运行代码——在 `src/models.py` 新增 `BallConv` 层（消息函数 `[x_src ■ x_dst ■ ball_src ■ ball_dst] → scatter_mean → BN → PReLU`），在 `src/gb_utils.py` 新增 `build_ball_tensor()` 构造节点→球的查表张量，在 `src/train.py` 新增 `--gb_btc` 与 `--gb_ball_emb_dim` 参数并把 BTCM 通路接到 `online + target` 双编码器，服务器侧 Photo 50ep × 1trial 冒烟跑出 0.8897，无 NaN 无维度报错。第二项是 Phase R（Photo / Computers 复跑验证）在服务器端跑完，4 组（R-A / R-B / R-C / R-D）全部 OK，总耗时仅 1h44min，结论是“粒球扩散对 Photo/Computers 没有显著增益， Δ vs baseline 在 $\pm 0.1pp$ 噪声范围内”，纠正了之前“Photo -0.20pp vs SGRL”的误读——Phase 0 baseline 自身就 -0.04pp，SGRL 的 93.95% 本身就是上限附近。第三项是服务器端 `src/data.py` 下载补丁——服务器 *16.20.21 内网阻断了 `shchur/gnn-benchmark`，PyG 的 `Amazon.download / Coauthor.download` 不检查文件存在直接拉、反复报 `ConnectionRefusedError`，用 `monkey-patch` 把两个类的 `download` 方法置空、强制走 `process()` 用已下载的 `raw`，三项问题（无 BTCM 代码、Phase R 未跑、数据集阻断）一次性解决。

二、Option BTCM：球扩散嵌入 TCM 路径（骨架落地）

2.1 设计思路

上周完成了 BTCM 的架构设计（见 `docs/RUNBOOK_NEXT_2026-07-02.md §2.2`），本周的目标是把“伪代码 → 代码”。当前 GCN 编码器的消息函数只用到两端节点特征，粒球信息只能通过末尾的 `granule_diffuse_and_write` 加性回写，无法在 GCN 内部“乘性”耦合。BTCM 把消息函数扩展为

\$\$

$$m_{ij} = \mathrm{BN}(\left(W \cdot \mathrm{concat}(\left[x_i, x_j, b_{\beta(i)}, b_{\beta(j)} \right] \right))$$

\$\$

其中 $b_{\beta(i)}$ 是节点 i 所属粒球 $\beta(i)$ 的嵌入 $H_{\{\mathrm{ball}\}}[\beta(i)]$, $\beta(i)$ 通过 `build_ball_tensor()` 一次性查表得到。这样 GCN 第一层就能感知"我属于哪类粒球", 球结构不再是 TCM 的旁路, 而是编码器本身的归纳偏置。

2.2 新增参数与脚本

变更

```
dim×2 + ball_dim×2 → out_dim, scatter_mean + BN + PReLU); `Conv` 加 `btc` / `ball_dim` 开关; `Online` / `Target` 加 `gb_ball_fe`  
nsor(H_ball, GB_node_list, N, device)`, 构造节点→球的查表张量  
`gb_ball_emb_dim=1024` 参数; `run()` 顶层构建 `gb_ball_tensor`; `train_online` / `train_target` 共享同一张量; BTCM 通路用 `prev_H_ball`  
(含 conda activate)  
到 `logs/nohup/btcm_smoke4.out`
```

关键 commit: e52388c wip: BTCM scaffold (BallConv + build_ball_tensor + prev_H_ball pipe), ball_dim=1024 default / 79f492e fix:■■TRAIN.PY / 5a362d4 fix:■■■■。

2.3 实验进展

服务器 Photo 50ep × 1trial 冒烟跑通:

```
[h_DEBUG] epoch=0000, ..., h_norm=8.36  
[h_DEBUG] epoch=0010, ..., h_norm=26.80  
[h_DEBUG] epoch=0040, ..., h_norm=28.48  
[TRIAL 1] ACC = 0.8897 ± 0.000038
```

无 NaN / 无维度报错, BTCM scaffold 端到端打通。Photo 50ep 0.8897 与 SGRL 同 epoch 的 0.93+ 相比还有 4pp+ 差距, 但这是训练时长问题而非代码问题——BTCM 50ep 完整 Photo / Computers / CS / Physics 跑要等 Phase R 完成后让出 GPU 才能正式起。

三、Phase R: Photo / Computers 复跑验证

3.1 设计思路

上周发现"Photo -0.20pp vs SGRL"这一 finding 的解读存在歧义：是 Stage-B Top-1 配置本身退化，还是 SGRL 复现本身就有 -0.20pp？为此设计了 Phase R：在不改动代码 / 不改超参的前提下，把 Stage-B Top-1 配置与"Phase 0 baseline (SGRL 等价的纯 GCN + BYOL, 不开 GB)"在同一台服务器、同一份数据、同一组 trial 序列下重跑，比较二者 Δ 。

- ☐ R-A / R-C: Phase 0 baseline (`--use_gb` 不开)，对应 SGRL 复现基线
- ☐ R-B / R-D: Stage-B Top-1 配置 (Photo detach/dot/0.3、K=10; Computers homo/dot/0.7)
- ☐ 每组 700ep $\times$ 5trial，对照 docs/PROGRESS_2026-07-02.md Stage-B Top-1 表

3.2 实验进展

服务器侧 scripts/phases/phaseR_repeat_validation.sh 在 PID 555977 后台跑，4 组全部 OK，总耗时 1h44min（远低于预估的 10 - 15h，因为 Photo / Computers 单 trial 实际只 4 - 15 min）：

组别	数据集	配置	5 trials mean	vs SGRL	Δ vs baseline
R-A	Photo	Phase 0 baseline (SGRL 等价, 无 GB)	**0.9391 $\pm$ 0.0007**	-0.04pp	—
R-B	Photo	Stage-B Top-1 (quity=detach, sim=dot, α =0.3, K=10)	**0.9380 $\pm$ 0.0008**	-0.15pp	**$-0.11pp$**
R-C	Computers	Phase 0 baseline	**0.9004 $\pm$ 0.0002**	-0.19pp	—
R-D	Computers	Stage-B Top-1 (quity=homo, sim=dot, α =0.7)	**0.8998 $\pm$ 0.0005**	-0.25pp	**$-0.06pp$**

核心结论：

- 之前 "Photo -0.20pp vs SGRL" 的 finding 不准确 —— Phase 0 baseline 自身就 -0.04pp，SGRL 的 93.95% 本身就是上限附近，并非我们的粒球模块把 SGRL 拉下来了
 - Stage-B Top-1 vs baseline 仅差 -0.11pp (Photo) 和 -0.06pp (Computers)，在 SGRL 标准差 $\pm 0.5pp$ 范围内
 - 粒球扩散 (GBGCL) 对 Photo/Computers 没有显著增益，基本就是 SGRL 噪声水平
 - BTCM 才是 GBGCL 论文真正的差异化方向，需要把球扩散嵌入 InfoNCE 才能拉开差距
- 后续：CS / Physics 还没跑过 Phase R，本周补跑 (CS 94.15% / Physics 96.23% 是 SGRL 最强的两个数据集，需要单独评估"GBGCL 在强基线上是否退化")。

3.3 当前状态

Phase R Photo / Computers 完成，已写入 results/phaseR/_summary.csv，本地用 tools/analyze_phaseR.py 出表。CS / Physics 排队等 GPU 让出 (BTCM 50ep 占 1 张 4090)。

四、data.py 下载补丁与服务器同步

Phase W 启动时已经修复过 scripts/phases/common.sh 的 --data_dir 绝对路径 (commit 5ba194f)，本周再补一个 src/data.py 的下载阻断补丁：服务器 *16.20.21 内网出口屏蔽了 shchur/gnn-benchmark, PyG 的 Amazon.download() / Coauthor.download() 不检查文件存在直接拉、反复 ConnectionRefusedError，导致任何 Photo / Computers / CS / Physics 启动都先挂一遍。

```
修法：在 src/data.py 顶部 monkey-patch:

import torch_geometric.datasets.amazon as _amz
import torch_geometric.datasets.coauthor as _coauth
def _skip_download(self):
    pass
_amz.Amazon.download = _skip_download
_coauth.Coauthor.download = _skip_download
```

强制走 process() 用已下载的 raw 目录，配合 common.sh 的 --data_dir=/home/ubuntu/workplace/tc2/GBGCL-main/datasets 绝对路径，Photo / CS / Computers / Physics 全部可以离线加载。

这次事故推动 RunBOOK 增加"服务器侧补丁登记"一栏：每条 sed 改动都要列"本地 commit / 服务器侧补丁 / 是否已 push"三栏。本周累积补丁清单：

改动	本地 commit	服务器侧补丁方式	是否已 push
sh `--data_dir` 绝对路径	`5ba194f`	scp `common.sh` + 重启 Phase W	否（本机防火墙挡 g
下载 monkey-patch	(在服务器 sed 注入)	服务器侧 sed 写入	否
affold	`e52388c` / `79f492e` / `5a362d4`	scp `models.py` `gb_utils.py` `train.py` 全量替换	否

五、论文撰写并行进展

本周与实验同步推进的论文写作包括：

☐ 方法小节 BTCM 算法描述补完：从上周的伪代码（runbook § 四.2）升级为可发布的算法 1，写清 BallConv 的消息函数、build_ball_tensor 的查表逻辑、以及 BTCM 通路在 train_online / train_target 的统一接法；同时把"prev_H_ball 跨 epoch 传递"的设计动机写明白——粒球结构本身是低频信号，每 epoch 重算反而引入抖动，跨 epoch EMA 比对 SGRL 的 TCM 更鲁棒。

- 消融实验设计修订：Phase R 的新结论（GBGCL 对 Photo / Computers $\approx$ SGRL $\pm$ 噪声）让消融章节的写法调整——Photo 不再当作“亮点”，CS 94.28% + BTCM smoke 0.8897 / 50ep 才是需要重点放大的点。消融维度同步改为“GB 注入位置（conv1 / conv2 / both） $\times$ ball_emb_dim（64 / 256 / 1024） $\times$ quity（detach / homo） $\times$ 球损失权重”四维网格，把 BTCM 与 Phase R 的实验数据合并到一张大表里。
- 结果对比表草稿：4 数据集 $\times$ {baseline, GBGCL-Stage-B-Top-1, GBGCL-BTCM} $\times$ 5trial 的对比框架已搭好，等待 BTCM 完整 700ep $\times$ 5trial 数据回填。Photo / Computers 现阶段结论“与 SGRL 持平”先占位写“GBGCL 不退化”，CS / Physics 留空待 BTCM 跑完补。

六、下一步工作计划

第一阶段是 Phase R CS / Physics 补跑（7/11 - 7/12），CS / Physics 是 SGRL 最强（94.15% / 96.23%）的两个数据集，评估 GBGCL 在强基线上是否退化的关键证据。脚本复用 `phaseR_repeat_validation.sh`，只需把 dataset 改为 CS / Physics，配置按 Stage-B Top-1 调参（CS 用 homo/dot/0.5、Physics 用 detach/dot/0.5）。

第二阶段是 BTCM 完整实验（7/13 - 7/16），把 Photo / Computers / CS / Physics 四数据集 $\times$ 700ep $\times$ 5trial 的 BTCM 跑齐，重点关注 BTCM 是否能在 Phase R baseline 基础上显著拉高（目标 $\Delta \geq +0.3pp$ / 数据集才算 BTCM 真正起效）；同时把 `ball_diffusion_btcn()` 真正嵌入 InfoNCE 的核心算法实现出来——当前 BTCM 只用 ball_feat 做消息注入，没有把球扩散嵌入 InfoNCE（runbook § 四.2 设计的目标形态），下半周要把“球邻居对作为 InfoNCE 正样本”这一关键改动落地并跑 smoke 验证。

第三阶段是论文方法小节定稿（7/16 - 7/17），把 BTCM 算法 1 补完、消融实验四维网格跑通、结果对比表 CS / Physics / BTCM 三块数据回填，提交本周末版周报。预期本周末可以把论文核心章节（方法 / 实验 / 消融）的 v1 完整版发给吴涛老师审阅。

本周的核心进展：Option BTCM 从伪代码落地为可运行骨架并跑通 Photo 50ep smoke；Phase R Photo / Computers 4 组全完，纠正了“Photo -0.20pp vs SGRL”的误读；data.py 下载补丁 + common.sh 绝对路径修复让服务器数据集离线可用。下周关键路径是 CS / Physics Phase R + BTCM 完整 700ep 实验——这一步决定论文“亮点”能否从 CS 单点扩散到多数据集。